Modul 21 — Sistem Deteksi Financial Fraud (Skripsi Statistika)

*Aplikasi web end-to-end untuk mendeteksi **indikasi** fraud pada laporan keuangan, dengan fokus pada ketepatan metodologi statistik, interpretabilitas, dan kejujuran ilmiah*

---

1. Informasi Project

Item	Keterangan
Nama	Sistem Deteksi Financial Fraud (folder `financial-fraud-detection`)
Jenis	Aplikasi data science + web: pipeline Python (statistik dan machine learning), API **FastAPI**, dan frontend **React 19 + TypeScript**
Konteks	Skripsi Statistika
Prinsip utama	Skor risiko adalah **indikasi untuk diperiksa lebih lanjut, bukan bukti fraud**
Data	`data/sample/` berisi data **sintetis** (`sample_fraud_data.csv` dan versi "kotor"). Untuk skripsi nyata, ganti dengan data perusahaan asli yang dipetakan ke skema `src/data/schema.py` (satuan Rupiah juta)
Isi	9 tahap pipeline, 36 fitur (termasuk 8 indeks Beneish), 4 model + 1 benchmark, 11 halaman web, laporan PDF
Pengujian	**171 uji Python** + **41 uji frontend** + typecheck
Dokumen pendamping	`README.md`, `DEMO.md` (panduan demo 5–7 menit untuk sidang), `reports/contoh_laporan.pdf`

2. Tujuan Pembuatan

1. Menyediakan **sistem deteksi indikasi fraud laporan keuangan** yang dapat dipertanggungjawabkan secara statistik di depan dosen penguji.
2. Menunjukkan metodologi yang benar untuk data tidak seimbang (fraud sekitar 6%): pembagian per perusahaan, resampling di dalam pipeline, nested CV, dan kalibrasi probabilitas.
3. Menjadikan model **dapat dijelaskan**: odds ratio dengan interpretasi teori, nilai Shapley eksak, dan penjelasan per perusahaan.
4. Menyajikan hasil dalam bentuk yang mudah dipakai: antarmuka web interaktif dan laporan PDF otomatis.
5. Bersikap **jujur tentang keterbatasan** (data sintetis, jumlah fraud sedikit, bias label) sebagai bagian dari argumen ilmiah.

3. Manfaat

- **Bagi mahasiswa/peneliti:** kerangka lengkap dari data mentah sampai laporan PDF, siap dipertahankan dalam sidang skripsi.
- **Bagi auditor atau analis:** memprioritaskan perusahaan yang layak diperiksa lebih dalam, dengan alasan yang bisa ditelusuri (faktor utama per perusahaan).
- **Bagi pembelajar statistik:** contoh nyata Beneish M-Score, Altman Z, uji Benford, regresi logistik Firth, kalibrasi Platt, DeLong, McNemar, dan decision curve.
- **Keputusan berbasis biaya:** ambang bisa digeser dengan slider, dan ambang bawaan berasal dari rasio biaya kesalahan (FN:FP = 10:1) yang dapat diubah.
- **Transparan:** setiap angka punya konteks (interval kepercayaan, uji signifikansi, asumsi).

> **Mengapa ini menarik?** Banyak proyek deteksi fraud berhenti pada "akurasi 95%". Sistem ini justru menjelaskan mengapa angka itu menyesatkan, lalu menunjukkan cara menilai model dengan benar.

4. Kelebihan & Kekurangan

Kelebihan

- **Anti-leakage yang tegas:** pembagian per perusahaan (data panel), resampling dan preprocessing di dalam `Pipeline`, nested CV, dan uji permutasi label yang membuktikan AUC ≈ 0,5 tanpa sinyal.
- **Metodologi lengkap:** 36 fitur rasio (tidak bergantung ukuran perusahaan), seleksi fitur Lasso + stability selection, VIF, uji Benford digit pertama dan terakhir.
- **Empat model + benchmark:** regresi logistik (IRLS + Firth), Random Forest, Gradient Boosting, Isolation Forest, dan Beneish M-Score.
- **Evaluasi jujur:** PR-AUC dan ROC-AUC dengan bootstrap per perusahaan, DeLong, McNemar, kalibrasi, decision curve. Pada data sampel tidak ada perbedaan signifikan antar model terawasi (Holm p ⩾ 0,74), jadi regresi logistik yang mudah ditafsirkan layak dipilih.
- **Penjelasan eksak:** nilai Shapley eksak (enumerasi 2^d koalisi, d ⩽ 14), permutation importance, odds ratio berinterpretasi teori, dan analisis *what-if*.
- Regresi logistik inferensial dan Shapley ditulis sendiri, diverifikasi terhadap scikit-learn, Hessian numerik, brute force, dan rumus analitik.
- **API rapi dan aman:** format galat seragam, batas unggah 20 MB, 5.000 baris per prediksi, `dataset_id` divalidasi regex, query SQL berparameter, detail galat internal tidak bocor ke klien.
- Pipeline **satu perintah** (`run_pipeline --quick`, ±6 menit) dan panduan demo siap pakai.
- Laporan PDF dengan font DejaVu Sans yang disertakan (lisensi bebas).

Kekurangan

- **Data sintetis:** hasil substantif skripsi harus memakai data asli; fitur pembulatan digit sengaja dibuat kuat pada generator, sehingga efeknya pada data nyata akan jauh lebih kecil.
- Fraud pada data uji hanya 43 kasus sehingga interval kepercayaan lebar.
- Label fraud nyata rentan *selection bias* dan *measurement bias*; model tidak menjamin generalisasi ke sektor atau periode lain.
- Seleksi fitur dilakukan sebelum CV, sehingga skor CV sedikit optimistis (angka akhir adalah hold-out).
- DeLong mengasumsikan independensi sehingga dilengkapi bootstrap berpasangan.
- Shapley eksak hanya praktis untuk ⩽ 14 fitur dan terhadap latar 40 baris latih.
- Penjelasan per baris dibatasi ⩽ 50 baris per permintaan.
- Instalasi Python agak berat (scikit-learn, statsmodels, SHAP, matplotlib, dll.).

- Frontend memakai CSS biasa (bukan Tailwind) dan grafik SVG buatan sendiri.

5. Stack Teknologi

Lapisan	Teknologi
Bahasa	Python 3.10+ (disarankan), TypeScript, SQL (SQLite)
Backend & API	FastAPI (>=0.110), Uvicorn, Pydantic 2, python-multipart
Data & statistik	NumPy, pandas, SciPy, scikit-learn (>=1.4), statsmodels, imbalanced-learn, pandera, openpyxl, joblib
Explainability	SHAP (opsional untuk pembanding), Shapley eksak buatan sendiri
Laporan PDF	ReportLab, matplotlib
Frontend	React 19, TypeScript 5.8, Vite 6, Zustand 5, Framer Motion 11, GSAP 3, Three.js 0.172 (hero dan gauge 3D), grafik SVG buatan sendiri
Database	SQLite bawaan Python (`sqlite3`) untuk riwayat prediksi; data analisis berupa berkas CSV/XLSX
Pengujian	pytest, httpx, pypdf (Python); skrip uji logika dan `tsc` (frontend)

Yang harus disiapkan

Python 3.10+ dan pip, Node.js 18+ dan npm, Git, editor kode (VS Code), ruang disk dan RAM yang cukup untuk paket ilmiah (disarankan RAM ≥ 8 GB), serta terminal. Tidak perlu server database: SQLite sudah ikut Python.

6. Cara Menjalankan (Detail)

6.1 Pemasangan

```
python -m venv .venv
source .venv/bin/activate           # Windows: .venv\Scripts\activate
pip install -r requirements.txt
```

6.2 Menjalankan pipeline (data → laporan)

```
python -m scripts.run_pipeline --quick   # data -> EDA -> fitur -> model ->
evaluasi -> penjelasan -> laporan (±6 menit)
python -m tests.run_all                  # 171 uji (atau: pytest tests -q)
```

Tiap tahap dapat dijalankan sendiri: `python -m scripts.run_eda`, `run_feature_engineering`, `run_modeling`, `run_evaluation`, `run_explanation`, `make_report` (PDF), `export_frontend_fixtures`, `generate_sample_data`.

6.3 Menjalankan aplikasi web

```
# Terminal 1: API (dokumentasi interaktif di http://localhost:8000/docs)
uvicorn src.api.main:app --port 8000

# Terminal 2: frontend
cd frontend
npm install
npm run dev                             # http://localhost:5173
```

Uji frontend: `npm test` (41 uji logika) dan `npm run typecheck`.

Mode satu proses: jalankan `npm run build` di folder `frontend`, lalu cukup `uvicorn src.api.main:app --port 8000` (API dan frontend disajikan bersama).

6.4 Memakai data perusahaan sendiri

1. Petakan kolom data Anda ke skema di `src/data/schema.py`: kolom identitas (`company_id`, `tahun`, `sektor`), kolom tahun berjalan, kolom tahun sebelumnya berakhiran `_prev`, dan label target. Satuan uang: **Rupiah juta**.
2. Unggah lewat halaman **Unggah & Validasi** (CSV atau XLSX, maks. 20 MB), atau ganti berkas di `data/`.

3. Jalankan ulang `python -m scripts.run_pipeline` agar model dilatih pada data Anda.

6.5 Cadangan untuk sidang

Bila laptop atau jaringan bermasalah: `python -m scripts.make_report` menghasilkan PDF di `reports/`, dan `reports/contoh_laporan.pdf` sudah disertakan.

7. Fungsi Halaman & Cara Mengoperasikan

7.1 Halaman Web (11 halaman)

Halaman	Fungsi	Cara pakai
Beranda	Pengantar sistem dan catatan bahwa data sampel sintetis	Klik **Coba dengan data sampel** untuk memulai cepat
Unggah & Validasi	Mengunggah dataset (CSV/XLSX) dan memeriksa kualitasnya	Pilih berkas atau sampel (termasuk sampel "kotor") → lihat laporan missing value, outlier, identitas neraca, dan kontinuitas panel (data tidak ditolak, hanya dilaporkan)
Eksplorasi Data (EDA)	Distribusi kelas, uji Benford, statistik ringkas	Buka tab *Distribusi kelas* (fraud ±6% sehingga akurasi menyesatkan) dan *Uji Benford* (digit pertama dan digit terakhir)
Feature Engineering	Katalog 36 fitur, rasio keuangan, M-Score, Altman Z	Lihat arah teori tiap fitur (**hipotesis**, bukan estimasi); M-Score dan Altman hanya benchmark
Prediksi Fraud	Skor risiko seluruh dataset	Pilih model (mis. Random Forest) → **geser slider ambang** → jumlah perusahaan yang ditandai berubah seketika; klik satu baris untuk gauge 3D

Halaman	Fungsi	Cara pakai
Analisis Perusahaan	Detail satu perusahaan	Lihat faktor utama (Shapley eksak); geser slider fitur (mis. DSRI) untuk simulasi *what-if*, dengan peringatan ekstrapolasi
Penjelasan Model	Odds ratio (forest plot), SHAP, permutation importance	Bandingkan efek tiap fitur dengan teori; lihat efek ambang pada fitur nonlinear
Evaluasi Model	PR-AUC, ROC-AUC, CI bootstrap, kalibrasi, DeLong	Bandingkan model; perhatikan CI yang lebar dan tidak adanya pemenang tunggal
Laporan PDF	Membuat laporan otomatis	Klik **Buat laporan PDF** → unduh
Riwayat	Daftar prediksi sebelumnya (SQLite)	Tinjau atau hapus riwayat
Tentang Model	Asumsi, keterbatasan, bias	Baca sebelum menyimpulkan hasil

7.2 Hasil pada Data Sampel (hold-out 720 baris, 43 fraud)

Model	PR-AUC	ROC-AUC
Random Forest	0,549	0,882
Gradient Boosting	0,543	0,871
Regresi Logistik	0,521	0,868
Isolation Forest	0,322	0,762
Beneish M-Score (benchmark)	0,220	0,799

Jangan menyimpulkan "model terbaik": selisihnya tidak signifikan (DeLong, Holm $p \geq 0{,}74$).

7.3 Endpoint API

Metode	Rute	Fungsi
GET	`/api/health`, `/api/models`, `/api/models/{nama}`, `/api/features/catalog`	Informasi sistem
POST	`/api/datasets`, `/api/datasets/sample`	Unggah + validasi; data sampel
GET / DELETE	`/api/datasets/{id}/preview`, `/eda`, `/features`; `DELETE /api/datasets/{id}`	Pratinjau, EDA, rasio
POST	`/api/predict/dataset`, `/api/predict/rows`, `/api/what-if`	Prediksi batch/tunggal dan *what-if*
POST	`/api/report`	Laporan PDF
GET / DELETE	`/api/results/{jenis}`, `/api/history`	Hasil analisis dan riwayat

7.4 Alur Demo 6,5 Menit (untuk sidang)

Beranda → Unggah & Validasi → EDA → Feature Engineering → Prediksi (geser ambang) → Analisis Perusahaan → Penjelasan Model → Evaluasi Model → Laporan PDF → Tentang Model. Detail dan jawaban pertanyaan dosen ada di `DEMO.md`.

7.5 Keputusan Metodologis yang Perlu Dijelaskan di Skripsi

- **Mengapa bukan akurasi?** Fraud ±6%: model yang selalu menjawab "tidak fraud" sudah 94% akurat. Gunakan PR-AUC, recall, dan kalibrasi.
- **Kalibrasi:** Platt scaling pada prediksi out-of-fold; ambang bawaan 9,1% berasal dari rasio biaya FN:FP = 10:1 (asumsi yang dapat diubah).
- **Inferensi:** bootstrap per perusahaan karena data panel.
- **Arah teori pada katalog fitur** adalah hipotesis (mis. Beneish 1999), bukan tanda koefisien estimasi.

8. Kalimat Penutup untuk Calon Pengguna

Sistem deteksi yang baik bukan yang paling yakin, melainkan yang paling jujur tentang apa yang ia ketahui dan tidak ketahui. **Proyek ini memberi Anda mesin analisis yang kuat sekaligus argumen ilmiah yang siap diuji di depan dosen penguji.** Jalankan pipeline satu perintah, buka halaman Prediksi, geser satu slider ambang — dan lihat sendiri bagaimana statistik yang benar mengubah angka menjadi keputusan.